INSTITUTO UNIVERSITÁRIO DE LISBOA

Mestrado em Engenharia de Telecomunicações e Informática

Segurança em Redes e Sistemas de Informação

Deteção de Anomalias e Redução de Falsos Positivos em Ambientes SIEM: Modelação Estatística de Ataques de Força Bruta

Autores:

Tomás Cerveira, 122617
Alexandre Duarte, 122657
Lara Machado, 122655
Eduardo Real, 122608

Docentes:
Daniel Pesqueira Morgado e Daniel Maximino Caçador

Repositório do Projeto (GitHub):
`https://github.com/LETI-122617/ISCTE-SIEM-Deteccao-Anomalias`

30-10-2026

Resumo

Os Centros de Operações de Segurança (SOC) enfrentam diariamente o desafio de processar grandes volumes de alertas gerados por sistemas de monitorização, sendo muitos destes alertas considerados falsos positivos que não representam ameaças reais. Este cenário gera "fadiga de alertas"e prejudica a capacidade de resposta a incidentes críticos. O presente trabalho aborda o problema da redução de falsos positivos em ambientes de Security Information and Event Management (SIEM), propondo a substituição de regras analíticas baseadas em limites estáticos por modelos de deteção adaptativos. Através da utilização de formulações estatísticas de média móvel e desvio padrão sobre eventos de autenticação, o estudo conceptualiza a diferenciação entre anomalias genuínas (ataques de força bruta a simular na Parte 2) e o ruído operacional normal da rede. A metodologia assentou numa revisão sistemática da literatura suportada pela plataforma Parsifal. A análise comparativa de 6 estudos de ponta indicou a viabilidade teórica da aplicação de métodos matemáticos (*Z-scores* e limiares adaptativos) na redução estatística de alarmes falsos. Esta abordagem nativa apresenta o potencial de contornar as latências proibitivas e as elevadas taxas de falsos positivos associadas a arquiteturas computacionalmente pesadas, como os *Large Language Models* (LLMs), estabelecendo as bases para a futura validação empírica.

Palavras-chave: SIEM, Falsos Positivos, Deteção de Anomalias, Força Bruta, SOC, Modelos Estatísticos.

Índice

Resumo **1**

Glossário **3**

1 Introdução **4**

2 Fundamentação Teórica **5**
2.1 Security Operations Centers e a Plataforma SIEM 5
2.2 Modelação Matemática da Deteção 5
2.3 Métricas de Avaliação de Desempenho 6

3 Estado da Arte e Revisão Sistemática **7**
3.1 Abordagens Atuais na Redução de Falsos Positivos 8
3.2 Síntese Comparativa 10

4 Conclusões e Trabalhos Futuros **10**

Referências **11**

Glossário

- **CMDB** – Configuration Management Database
- **EC** – Exclusion Criteria (Critério de Exclusão)
- **FN** – *False Negative* (Falso Negativo)
- **FP** – *False Positive* (Falso Positivo)
- **FPR** – False Positive Rate
- **IAM** – Identity and Access Management
- **IC** – Inclusion Criteria (Critério de Inclusão)
- **IDS** – Intrusion Detection System
- **KQL** – Kibana Query Language
- **LLM** – Large Language Model
- **MAD** – Median Absolute Deviation (Desvio Absoluto da Mediana)
- **MITRE ATT&CK** – Adversarial Tactics, Techniques, and Common Knowledge
- **ML** – Machine Learning
- **ROC-AUC** – Receiver Operating Characteristic - Area Under Curve
- **RQ** – Research Question (Questão de Pesquisa)
- **SIEM** – Security Information and Event Management
- **SOC** – Security Operations Center
- **SPL** – Search Processing Language
- **SSH** – Secure Shell
- **TCS** – Threat Confidence Score
- **TN** – *True Negative* (Negativo Verdadeiro)
- **TP** – *True Positive* (Positivo Verdadeiro)

1 Introdução

A capacidade de monitorizar redes e sistemas informáticos em tempo real é um pilar fundamental da cibersegurança. No entanto, existe um problema crítico relacionado com a eficácia das ferramentas de monitorização: a geração de um grande volume de alertas que não representam a real situação do ambiente computacional, dificultando a análise feita pelos administradores de sistemas. Estes falsos positivos obrigam as equipas de analistas a desperdiçar recursos na triagem de eventos benignos, atrasando a resposta a verdadeiros incidentes de segurança.

Este projeto visa resolver o problema da ineficiência na deteção de intrusões provocada por regras de alerta estáticas. Como a literatura recente demonstra, a adoção de Inteligência Artificial massiva (como LLMs) para tentar solucionar este problema tem introduzido latências incompatíveis com o processamento em tempo real e agravado as taxas de falsos positivos (FPR) devido ao viés computacional. Para endereçar este desafio de forma otimizada, propõe-se o estudo e fundamentação teórica de um modelo adaptativo num ambiente SIEM, focado na aplicação nativa de funções matemáticas e estatísticas descritivas para estabelecer *baselines* de comportamento normal na rede. Ao conceptualizar o cálculo de desvios padrão dinâmicos e *Z-scores*, procura-se avaliar em que medida o sistema pode filtrar o ruído benigno e identificar ataques de força bruta com um custo computacional residual.

O documento encontra-se estruturado da seguinte forma: a Secção 2 apresenta a fundamentação teórica, detalhando a arquitetura SIEM e o impacto da fadiga de alertas num SOC; a Secção 3 detalha a revisão sistemática da literatura e o estado da arte das abordagens de mitigação de ruído; por fim, a Secção 4 expõe as conclusões teóricas alcançadas e os trabalhos futuros delineados para o desenvolvimento prático deste projeto.

2 Fundamentação Teórica

2.1 Security Operations Centers e a Plataforma SIEM

Os *Security Operations Centers* (SOCs) desempenham um papel crítico na cibersegurança das organizações, garantindo a monitorização contínua, deteção e resposta a incidentes. O núcleo tecnológico destas operações assenta em plataformas *Security Information and Event Management* (SIEM), que agregam volumes massivos de dados provenientes de sistemas de deteção e prevenção de intrusões (IDS/IPS) [5].

Contudo, o crescimento exponencial do volume de dados gerados tem provocado um fenómeno severo de fadiga de alertas (*alert fatigue*) entre as equipas de analistas. Este problema é impulsionado, na sua grande maioria, por elevadas taxas de falsos positivos resultantes de regras de deteção estáticas que carecem de contexto organizacional. A literatura demonstra a escala operacional deste desafio: os analistas operam sob intensa pressão temporal, conseguindo rever apenas uma fração dos alertas [4, 5]. O impacto é massivo, uma vez que as operações de SOC recebem frequentemente mais de 10.000 eventos diários, estimando-se que cerca de 90% destes registos representem falsos positivos [6]. A ausência de adaptação dinâmica aos padrões de atividade normal da rede torna a monitorização ineficiente, resultando em respostas atrasadas, incidentes ignorados e exaustão psicológica das equipas de segurança [4].

2.2 Modelação Matemática da Deteção

Para colmatar as falhas das abordagens baseadas em limites estáticos e evitar a sobrecarga de arquiteturas *black-box* de inteligência artificial, a nossa proposta teórica assenta na identificação de anomalias através da estatística descritiva aplicada nativamente aos *logs* do SIEM. Esta lógica assemelha-se à modelação de desvios padronizados (*Z-scores*) demonstrada por Mohanapriya et al. (2026), mas calculada em tempo real sobre séries temporais de eventos.

O volume de eventos de autenticação falhados num instante t, denotado por X_t, é avaliado em relação ao histórico de tráfego. A média móvel (μ) e o desvio padrão (σ) para uma janela de tempo com N observações anteriores (excluindo propositadamente o instante atual X_t no somatório de $i = 1$ a N, para que o pico anómalo não mascare a própria *baseline*) são calculados através das seguintes formulações matemáticas:

$$\mu = \frac{1}{N} \sum_{i=1}^{N} X_{t-i} \tag{1}$$

$$\sigma = \sqrt{\frac{1}{N} \sum_{i=1}^{N} (X_{t-i} - \mu)^2} \tag{2}$$

Com base nestas métricas, o desvio normalizado (*Z-score*) do tráfego atual é calculado para quantificar a distância do evento face ao comportamento esperado. Para evitar indeterminações matemáticas em janelas de tempo com tráfego perfeitamente constante (onde $\sigma = 0$), introduz-se uma constante residual ϵ (e.g., $\epsilon = 1$, garantindo um limite mínimo de variação natural aceitável):

$$Z_t = \frac{X_t - \mu}{\sigma + \epsilon} \tag{3}$$

Um alerta é acionado, indicando um potencial ataque de força bruta, se o desvio atual ultrapassar uma constante de limiar k (onde $Z_t > k$). Matematicamente, resolvendo a inequação para o volume de eventos no SIEM, obtemos o critério direto de deteção da nossa arquitetura:

$$X_t > \mu + k\sigma \tag{4}$$

A constante k atua como o calibrador de sensibilidade do SOC, sendo tipicamente definida com o valor 3, baseando-se na regra empírica da estatística para abranger 99,7% do tráfego legítimo esperado. Refira-se que esta formulação assume uma distribuição aproximadamente normal das contagens de eventos, premissa que será validada com dados reais na Parte 2 do projeto.

Reconhece-se ainda a limitação inerente da contaminação da *baseline*: um ataque lento e prolongado (*low and slow*) pode inflacionar gradualmente os valores de μ e σ, mascarando a anomalia. Em trabalhos futuros, esta lacuna poderá ser mitigada pela exclusão de pontos já sinalizados da janela temporal ou pelo uso do Desvio Absoluto da Mediana (MAD). Do ponto de vista operacional, o cálculo contínuo destas métricas pode ser implementado de forma nativa através de linguagens de pesquisa do SIEM, como o *Search Processing Language* (SPL) no Splunk (recorrendo ao comando `streamstats`) ou o *Kibana Query Language* (KQL) na *Elastic Stack*, dispensando *hardware* dedicado.

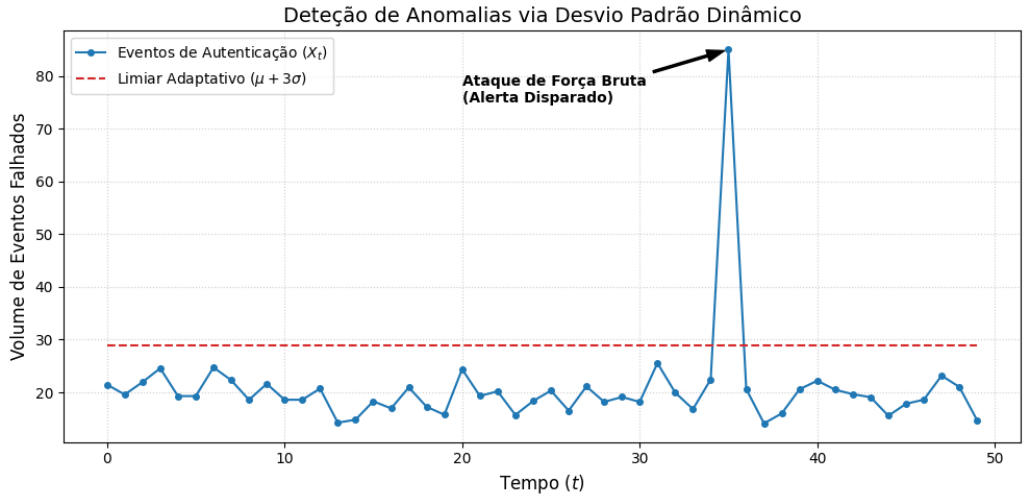


Figura 1: Representação conceptual do limiar adaptativo ($\mu+k\sigma$) a isolar um pico anómalo de eventos de autenticação num SOC.

2.3 Métricas de Avaliação de Desempenho

Para validar a eficácia do modelo estatístico proposto e permitir uma comparação justa com as abordagens de *Machine Learning* identificadas no estado da arte, o desempenho da deteção deve ser medido recorrendo à matriz de confusão. A avaliação da eficácia na redução de falsos positivos num SOC baseia-se nas seguintes métricas matemáticas:

Precisão (*Precision*): Avalia a proporção de alertas classificados como anómalos que correspondem a verdadeiros ataques, mitigando o ruído operacional:

$$Precision = \frac{TP}{TP + FP} \tag{5}$$

Sensibilidade (*Recall*): Mede a capacidade do modelo em detetar a totalidade das ameaças reais, garantindo que incidentes críticos não são ignorados:

$$Recall = \frac{TP}{TP + FN} \tag{6}$$

Especificidade (*Specificity*): Quantifica a capacidade do sistema em classificar corretamente o tráfego benigno, essencial para não gerar falsos alarmes:

$$Specificity = \frac{TN}{TN + FP} \tag{7}$$

***F-Score*:** Representa a média harmónica entre a Precisão e a Sensibilidade. Num ambiente SIEM, caracterizado por um forte desbalanceamento de classes (onde o volume de eventos benignos é ordens de grandeza superior ao de ataques), esta métrica é um dos indicadores mais robustos para avaliar o modelo:

$$F\text{-}Score = 2 \times \frac{Precision \times Recall}{Precision + Recall} \tag{8}$$

3 Estado da Arte e Revisão Sistemática

Para compreender as abordagens atuais à redução de alertas, foi elaborado um protocolo de revisão sistemática de literatura, definindo o problema, questões de pesquisa principais e estatísticas. A pesquisa foi conduzida em bases de dados bibliográficas, tendo os estudos sido selecionados através de rigorosos critérios de inclusão e exclusão filtrados pelo título e *abstract*.

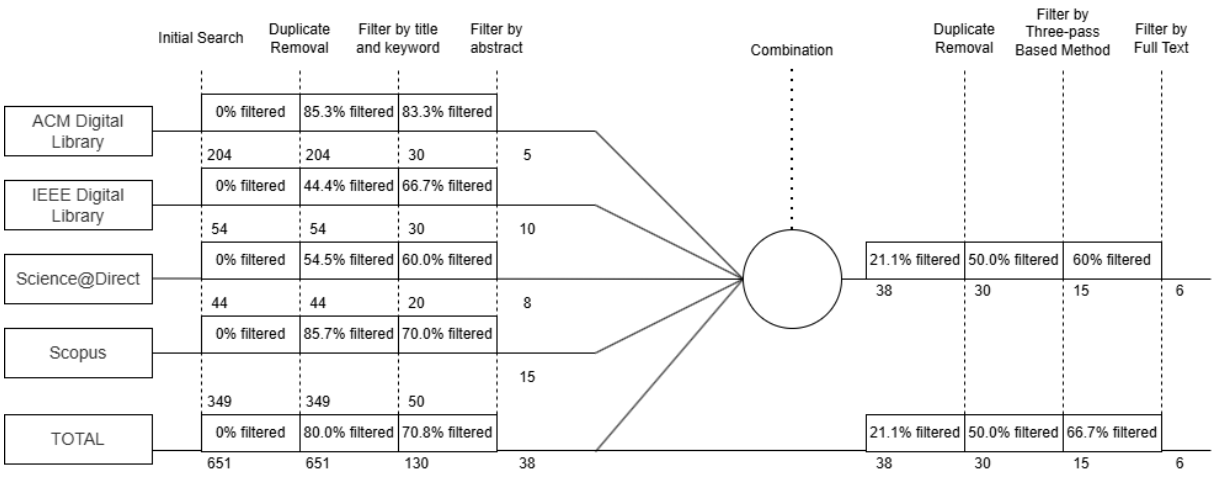


Figura 2: Fluxo do processo de seleção de estudos da revisão sistemática da literatura.

Para garantir o rigor metodológico, a revisão seguiu diretrizes estruturadas na plataforma Parsifal. A investigação foi norteada por duas Questões de Pesquisa (RQ) fundamentais: **RQ1:** Quais as limitações operacionais das soluções baseadas em IA (ML e LLMs) num SOC? **RQ2:** Como podem os modelos estatísticos adaptativos otimizar a redução de falsos positivos?

A extração de dados incidiu sobre publicações da última década (2016-2026), utilizando a *string* de busca: `("SIEM"OR "SOC") AND ("false positive*"OR "alert fatigue")`

`AND ("anomaly detection"OR "statistical modeling")`. Aplicou-se um Critério de Inclusão (**IC1**): estudos com foco explícito em ambientes SIEM, redução de fadiga de alertas ou modelação de anomalias em tráfego de rede.

O processo de triagem (Figura 2) iniciou-se com 651 artigos recolhidos de bases de dados científicas (ACM, IEEE, ScienceDirect e Scopus). Numa primeira fase local de remoção de duplicados, não se registaram exclusões, transitando os 651 artigos para a filtragem por título e palavras-chave, que reduziu a amostra substancialmente para 130 documentos. A subsequente filtragem por *abstract* isolou 38 artigos. Após a combinação dos resultados das quatro bases, realizou-se uma segunda remoção de duplicados globais (restando 30 artigos), seguida de uma triagem pelo método de três passagens (*Three-pass Based Method*), que reduziu o conjunto para 15 trabalhos. Por fim, na fase de leitura integral (*Full Text*), aplicaram-se dois Critérios de Exclusão (EC) principais: **EC1** rejeitou trabalhos fora do âmbito de TI tradicional (e.g., redes de água ou IoT industrial); **EC2** excluiu publicações puramente teóricas ou focadas em partilha federada sem métricas de mitigação de ruído. Este processo iterativo e rigoroso culminou na seleção final de 6 estudos para análise aprofundada.

3.1 Abordagens Atuais na Redução de Falsos Positivos

Para mitigar a fadiga de alertas, a comunidade académica tem explorado soluções avançadas que visam injetar contexto e dinamicidade na classificação de eventos. Trabalhos de referência exploram a aplicação de algoritmos de aprendizado de máquina supervisionado aliados ao enriquecimento de atributos organizacionais. Moraes et al. (2017) propuseram uma arquitetura de duas fases aplicada aos *logs* de um IDS Snort: primeiramente, os alertas informativos de baixa prioridade (prioridade 3) são filtrados de forma estática, o que num estudo de caso real reduziu o volume bruto de mais de 2,2 milhões de alertas mensais para cerca de 26 mil [3]. Numa segunda fase, os alertas críticos sobreviventes são enriquecidos com dados externos (como geolocalização via *GeoIP*) e topologia da rede (papel e função do *host*) [3]. Ao submeter estes dados a classificadores, o estudo demonstrou que o algoritmo *Random Forest* supera o *k-Nearest Neighbors* (kNN) na robustez perante o desbalanceamento de classes, alcançando taxas de precisão, sensibilidade e especificidade sistematicamente entre os 95,08% e os 100% na identificação final de falsos positivos [3].

Expandindo a aplicação empírica de Inteligência Artificial, Yauri et al. (2026) avaliaram o desempenho de modelos de *Machine Learning* (ML) processando 98.321 registos reais extraídos de uma firewall Palo Alto num ambiente SIEM [6]. O estudo aplicou técnicas rigorosas de pré-processamento, recorrendo ao agrupamento não supervisionado (*K-Means*) para validação de especialistas, além da transformação de variáveis categóricas utilizando *Weight of Evidence* (WoE) e *Information Value* (IV) [6]. Após a avaliação e afinação de hiperparâmetros em dez classificadores distintos, o modelo *Gradient Boosting* destacou-se com uma área sob a curva (ROC-AUC) de 0.9964 e um *F1-score* de 97.32% [6]. A eficácia da otimização refletiu-se de forma substancial na matriz de confusão: num universo de teste superior a 18.600 eventos, o modelo registou apenas 120 falsos positivos e 259 falsos negativos, validando a capacidade destes algoritmos em filtrar ruído sem comprometer a identificação atempada de incidentes críticos [6].

Aprofundando a eficácia das abordagens construídas nativamente em plataformas SIEM, Bhardwaj (2026) propôs uma metodologia de *threat hunting* focada na correlação comportamental para detetar vetores de acesso inicial (como documentos maliciosos e execução de *LOLBins*) operando num ambiente *Elasticsearch* [1]. O autor desenvolveu um

modelo de Pontuação de Confiança de Ameaça (*Threat Confidence Score* - TCS) baseado em pesquisas multicondicionais de linhagem de processos (relação pai-filho e argumentos de linha de comando) [1]. Num teste empírico que recorreu a telemetria real de produção, o sistema ingeriu exatamente 12.079.598 eventos de *log* [1]. A aplicação desta lógica de triagem comportamental conseguiu reduzir este volume massivo para apenas 54 potenciais alertas [1]. Após validação, o modelo confirmou 3 verdadeiros positivos e suprimiu o ruído para apenas 2 falsos positivos, alcançando uma taxa de sensibilidade (*recall*) perfeita de 1.0 e um *F1-score* equilibrado de 75% [1]. Embora estes resultados atestem uma elevada fiabilidade na filtragem de ruído sem dependência de algoritmos externos pesados, a limitação operacional desta solução reside na necessidade de desenhar, afinar e manter arquiteturas complexas de regras encadeadas e limiares de risco definidos manualmente por especialistas com base na *framework* MITRE ATT&CK [1].

Em contraponto ao sucesso da modelação comportamental, a aplicação recente de *Large Language Models* (LLMs) na triagem de alertas SIEM tem revelado severas limitações operacionais [4]. Num estudo comparativo exaustivo, Rieger et al. (2026) avaliaram modelos de ponta (como as famílias GPT-4, DeepSeek e Olmo 3) contra classificadores estatísticos e baseline tradicionais [4]. Os resultados demonstraram que, embora os LLMs atinjam taxas de sensibilidade elevadas, geram uma quantidade insustentável de ruído e sofrem de sobreclassificação constante [4]. O modelo *Olmo 3*, por exemplo, registou uma taxa de falsos positivos (FPR) de 90.54%, enquanto o *GPT-4o-mini* atingiu 72.97% de FPR, agravando severamente a fadiga de alertas que se propunham resolver [4]. Além da imprecisão analítica, a latência computacional mostrou-se proibitiva para ambientes reais, com modelos a demorarem até 85.8 segundos (*DeepSeek-Reasoner*) para processar um único alerta [4].

Corroborando esta ineficiência e a complexidade operacional dos modelos generativos, Roy e Balde (2026) avaliaram o uso do modelo massivo *Meta LLaMA 3.3-70B* na classificação de alertas de nível 1 num ambiente SIEM Wazuh [5]. A investigação demonstrou que, na ausência de contexto organizacional detalhado, o LLM assume um "viés de cautela"(gerando falsos positivos) e sofre de variabilidade nas suas decisões, alcançando uma precisão de apenas 80% [5]. Embora os autores provem que a injeção contínua de ficheiros JSON com contexto estruturado consegue mitigar os falsos positivos, esta abordagem exige a integração e manutenção de bases de dados contextuais dinâmicas (como sistemas CMDB e IAM) acopladas a um modelo de 70 mil milhões de parâmetros [5].

Em paralelo às abordagens generativas, arquiteturas híbridas como a plataforma GarudanEye, proposta por Mohanapriya et al. (2026), evidenciam o potencial de combinar múltiplos métodos de deteção com modelos matemáticos de desvio [2]. Processando 2,83 milhões de registos de tráfego de rede, o sistema integra classificação de *Random Forest* com o cálculo de desvios padronizados (*Z-scores*) para estabelecer perfis de anomalias com base na média e no desvio padrão das características da rede [2]. Esta abordagem híbrida resultou num FPR excecionalmente baixo de 0.0022 e numa precisão global de 96.91% [2], indicando que a identificação de anomalias com base em métodos estatísticos de desvio consegue diferenciar eficazmente o tráfego benigno das instâncias de ataque, mitigando o ruído de alertas com alta eficiência computacional [2].

Em suma, a literatura mais recente demonstra que a Inteligência Artificial pesada, embora promissora em testes isolados, introduz dependências arquitetónicas, propensão para falsos positivos e custos computacionais que contrariam a necessidade de agilidade e automação de um SOC. É exatamente para colmatar esta lacuna técnica e estrutural que o presente projeto se insere: em vez de recorrer a modelos *black-box* morosos ou regras

encadeadas manuais, propomos o uso nativo do **Desvio Padrão Dinâmico** e **Médias Móveis** diretamente no motor de correlação do SIEM. Esta abordagem procura isolar anomalias com um *overhead* esperado reduzido, pretendendo minimizar falsos positivos em tempo real sem *hardware* dispendioso ou treino complexo.

3.2 Síntese Comparativa

É crucial salientar que os resultados numéricos reportados na literatura não são diretamente comparáveis de forma absoluta, dado que os estudos utilizam *datasets* (e.g., CICIDS2017 vs. telemetria real fechada), escalas operacionais e métricas primárias de avaliação distintas. Servem, ainda assim, como indicadores do comportamento das arquiteturas. A Tabela 1 resume as metodologias analisadas e evidencia o posicionamento da nossa formulação estatística face às limitações identificadas.

Tabela 1: Comparativo das Abordagens na Literatura para Redução de Falsos Positivos em SIEM

Estudo	**Metodologia / Tecnologia**	**Dataset / Escala**	**Métrica Principal**	**Vantagem Evidenciada**	**Limitação Operacional (SOC)**
Moraes et al. (2017) [3]	Machine Learning (kNN e RF)	Logs Snort (2M alertas)	Precisão ≈ 100%	Excelente classificação estática	Exige extração de dados e treino externo
Yauri et al. (2026) [6]	Gradient Boosting	Logs Palo Alto (98K ev.)	ROC-AUC: 0.996	Alta separação comportamental	Otimização complexa de hiperparâmetros
Bhardwaj (2026) [1]	Correlação Comportamental	Telemetria Real (12M logs)	F1-Score: 75%	Filtra eventos fidedignos de ruído	Requer regras encadeadas complexas
Rieger et al. (2026) [4]	LLMs vs. ML (Linear SVM)	Dataset simulado (178 alertas)	FPR: 90.5% (LLMs)	ML leve supera LLMs na triagem	LLMs geram latência alta (85s) e ruído
Roy & Balde (2026) [5]	LLMs (Meta LLaMA 3.3-70B)	Cyber-Range (55 alertas)	Accuracy: 100%	Injeção direta de contexto	Exige manutenção contínua de bases
Mohanapriya et al. (2026) [2]	Híbrida (RF + Z-scores)	CICIDS2017 (2.8M logs)	FPR: 0.0022	FPR excecionalmente baixo	Requer conjugação de múltiplos motores
Nossa Proposta	**Estatística Nativa (Desvio Padrão)**	**A simular (Parte 2)**	**A calcular (Parte 2)**	**Vantagem Esperada:** Baixa latência	**Âmbito restrito a força bruta**

4 Conclusões e Trabalhos Futuros

O presente trabalho evidencia, através da revisão sistemática da literatura, que a dependência de assinaturas estáticas na deteção de intrusões contribui severamente para a fadiga de alertas num SOC. O estado da arte indica que, embora abordagens baseadas em inteligência artificial (LLMs e ML complexo) consigam atenuar a taxa de falsos positivos (FPR), estas acarretam complexidade computacional, latências elevadas e necessitam de manutenção manual exaustiva de bases de contexto organizacional. Conclui-se concetualmente que a aplicação nativa de modelos estatísticos dinâmicos diretamente na plataforma SIEM apresenta o potencial de autoajustar limiares, visando suprimir ruído sem introduzir um *overhead* insustentável nas operações.

Trabalhos Futuros: No âmbito da continuidade deste projeto (Parte 2), a arquitetura teórica proposta será alvo de validação empírica. Os trabalhos futuros focar-se-ão em três eixos centrais:

1. **Implementação Prática:** Materialização do modelo matemático através de *queries* nativas em plataformas reais (e.g., Splunk via SPL ou Elastic Stack via KQL).

2. **Simulação e Calibração:** Geração de tráfego benigno mesclado com simulações de ataques de força bruta, procedendo à calibração empírica da janela temporal (N) e da constante de sensibilidade (k). Adicionalmente, será abordada a mitigação da sazonalidade natural do tráfego (padrões diurnos/noturnos).

3. **Avaliação de Desempenho:** Extração das métricas (Precisão, Sensibilidade, Especificidade e *F-Score*) e comparação direta com um cenário de limiares estáticos, **avaliando** a redução quantitativa da taxa de falsos positivos (FPR).

Referências

[1] Bhardwaj, A. (2026). *Security framework for threat hunting advanced adversaries for initial level access. Computer Networks*, 288, 112630. https://doi.org/10.1016/j.comnet.2026.112630

[2] Mohanapriya, D., Dharsini, C., Arun, K., Jayapriya, M., & Chandhru, V. (2026). *GarudanEye: An Intelligent Threat Detection and Response Platform.* In *Proceedings of the 4th International Conference on Self Sustainable Artificial Intelligence Systems (ICSSAS)*, 1738-1743, IEEE. https://doi.org/10.1109/ICSSAS68835.2026.11559399

[3] Moraes, E. A., Tojeiro, C. A. C., Miani, R. S., & Zarpelão, B. B. (2017). *Análise de Alertas de Sistemas de Detecção de Intrusão: Uso de Aprendizado Supervisionado na Redução de Alertas Falsos Positivos.* In *Anais do XVII Simpósio Brasileiro de Segurança da Informação e de Sistemas Computacionais (SBSeg)*, 182-195, SBC. https://doi.org/10.5753/sbseg.2017.19499

[4] Rieger, M., Shah, A., Alam, A., & Hossain, M. J. (2026). *Possibilities and limitations of using large language models (LLMs) for alert classification and prioritisation in security operations centers (SOCs). Expert Systems With Applications*, 331, 133194. https://doi.org/10.1016/j.eswa.2026.133194

[5] Roy, J., & Balde, E. A. (2026). *Toward Context-Aware Alert Classification in Security Operations Centers Using LLMs.* In *5th IEEE International Conference on AI in Cybersecurity (ICAIC)*, Houston, TX, IEEE. https://doi.org/10.1109/ICAIC67076.2026.11395735

[6] Yauri, C., Gutiérrez, R., Cárdenas, J., & Ticona, W. (2026). *Model for Detecting Security Events from SIEM Logs Using Machine Learning Techniques. Universidad ESAN & Universidad Tecnológica de Perú*, Lima, Perú. https://doi.org/10.1007/978-3-032-22091-2_14